

엔트로피와 허프만부호

금오공과 대학교 전자공학부

Mobile Communications and Coding Lab.

송영준 교수

정보의 표현

정보와 정보량

- ❖ 자기 정보량(self-information): 정보 이론에서 특정 사건이 발생할 때 얻는 정보의 양을 정량화한 개념. 이 개념은 **클로드 섀넌(Claude Shannon)**에 의해 도입. 자기 정보량은 정보의 '놀라움' 또는 '예측 불가능성'을 수치로 표현:

$$I(A) = -\log_2 P(A) \text{ [bits]}$$

- 정보량의 단위는 비트(bits)
- 자기 정보량은 특정 사건 A 가 발생할 확률 $P(A)$ 를 사용하여 계산
- 높은 확률로 발생하는 사건(예측이 쉬운 사건)은 낮은 정보량, 반대로 예측하기 어려운 사건은 높은 정보량
- 데이터 압축, 이동통신 등 다양한 분야에서 활용

예제 1) 동전을 한 번 던질 때 앞면이 나올 확률이 $P(\text{앞면})=0.5$ 라 가정하면, $I(\text{앞면}) = -\log_2 P(\text{앞면}) = 1 \text{ bit}$

예제 2) 주사위를 한 번 던질 때 특정 숫자가 나올 확률이 $P(\text{특정숫자})=1/6$ 라 가정하면, $I(\text{특정 숫자}) = -\log_2 P(\text{특정숫자}) \approx 2.585 \text{ bits}$

예제 3) 어떤 이벤트가 발생할 확률이 $P(\text{이벤트})=1/16$ 라 가정하면, $I(\text{이벤트}) = -\log_2 P(\text{이벤트}) = 4 \text{ bits}$

엔트로피

- 엔트로피(entropy) 또는 평균 자기 정보량(average self-information)은 메시지 또는 신호 소스에서 생성되는 정보의 평균적인 불확실성 또는 예측 불가능성을 나타낸다. 이 개념은 정보의 양을 정량화하는 데 사용된다.
- 엔트로피 $H(X)$ 는 확률변수 X 의 가능한 모든 사건들에 대한 자기 정보량의 기대값으로 정의:

$$H(X) = -\sum_i P(x_i) \log_2 P(x_i) \text{ [bits]}$$

- ✓ $P(x_i)$ 는 확률 변수 X 가 특정 상태 x_i 를 취할 확률이다.
- ✓ 엔트로피는 신호나 메시지 소스의 불확실성의 정도를 측정
- ✓ 엔트로피가 높을수록 예측하기 어렵고, 더 많은 정보를 포함
- ✓ 모든 사건들이 동일한 확률로 발생할 때, 엔트로피는 최대값
- ✓ 정보 소스의 엔트로피를 이해하면 데이터를 압축하거나 전송하는 과정에서 필요한 최소한의 비트 수를 결정
- ✓ 데이터의 엔트로피를 계산함으로써 최적의 압축률을 결정
- ✓ 통신 채널의 용량을 계산하고, 효율적인 데이터 전송 방법을 개발하는 데 사용
- ✓ 암호 시스템의 강도를 평가하는 데 사용되며, 더 높은 엔트로피는 더 강력한 암호를 의미

베르누이 확률변수

베르누이 확률 변수(Bernoulli random variable)는 단 두 가지 결과만을 가지는 실험 또는 확률 과정을 설명하는데 사용된다. 이러한 실험 결과는 일반적으로 **성공**과 **실패**로 불리며, 1 (성공) 또는 0 (실패)의 값을 갖는다. 베르누이 확률 변수의 가장 대표적인 예는 동전 던지기이다.

예제:


- 동전을 한 번 던질 때, 앞면이 나오면 "성공" (1), 뒷면이 나오면 "실패" (0)으로 정의할 수 있다.
- 이 경우, 앞면이 나올 확률을 p 라고 할 때, 베르누이 확률 변수 X 는 다음과 같이 정의된다:
 - $X = 1$ (앞면, "성공") with probability p
 - $X = 0$ (뒷면, "실패") with probability $1 - p$
- 여기서 p 는 동전의 앞면이 나올 확률이며, 대부분의 정상적인 동전의 경우 $p = 0.5$ 이다.

엔트로피 계산 (베르누이 확률변수)

- 베르누이 확률변수의 엔트로피:

$$H(X) = H_2(p) = H(p, 1 - p) = -p \log_2 p - (1 - p) \log_2 (1 - p)$$

- 아래의 그래프는 베르누이(Bernoulli) 확률 변수의 엔트로피를 확률 p 가 0부터 1까지 변할 때 어떻게 변하는지 보여준다.
- 엔트로피는 확률 $p = 0.5$ (즉, 성공과 실패의 확률이 동일할 때)에서 최대값을 가지며, p 가 0이나 1에 가까워질수록 (결과의 불확실성이 가장 낮을 때) 엔트로피는 0으로 감소한다.



엔트로피 계산 (영어 알파벳)

❖ 영어 알파벳의 사용 빈도는 여러 출처에서 조사된 결과에 따라 약간씩 차이가 있을 수 있지만, 대체로 일반적인 텍스트에서 가장 빈번하게 사용되는 알파벳은 'e', 't', 'a', 'o', 'i', 'n', 's', 'h', 'r'. 반면 'z', 'q', 'x', 'j', 'k'와 같은 알파벳은 상대적으로 덜 사용

❖ 영어 알파벳 사용 빈도 예시:

'a': 8.2, 'b': 1.5, 'c': 2.8, 'd': 4.3, 'e': 12.7, 'f': 2.2, 'g': 2.0, 'h': 6.1, 'i': 7.0, 'j': 0.2, 'k': 0.8, 'l': 4.0, 'm': 2.4, 'n': 6.7, 'o': 7.5, 'p': 1.9, 'q': 0.1, 'r': 6.0, 's': 6.3, 't': 9.1, 'u': 2.8, 'v': 1.0, 'w': 2.4, 'x': 0.2, 'y': 2.0, 'z': 0.1

$$H(X) = -\sum_{i=1}^{26} P(x_i) \log_2 P(x_i) = 4.192 \text{ [bits]}$$

❖ 주어진 영어 알파벳의 사용 빈도를 기반으로 계산한 엔트로피는 약 4.19 비트이며, 이는 영어 텍스트에서 각 알파벳이 나타날 때의 평균적인 정보량(불확실성)을 나타낸다. 즉, 영어 텍스트에서 한 글자를 읽을 때 평균적으로 약 4.19 비트의 정보를 얻는다.

엔트로피 응용 (허프만 부호)

허프만 부호(Huffman Coding)는 데이터 압축에 사용되는 효율적인 부호화 방법이다. 1952년 데이비드 허프만 (David Huffman)에 의해 개발된 이 알고리즘은 **무손실 압축**을 제공하며, 특히 파일 압축 및 데이터 전송에서 널리 사용된다. **허프만 부호의 원리**는 다음과 같다.

- **빈도 기반 부호화**: 허프만 부호화는 문자 또는 심볼의 등장 빈도에 기반하여 가변 길이의 비트 패턴(부호)을 할당한다. 더 자주 나타나는 문자에는 더 짧은 부호를, 더 드물게 나타나는 문자에는 더 긴 부호를 할당한다.
- **이진 트리 구조**: 이진 트리 (Tree)를 구성하여 각 문자에 대한 부호를 생성한다. 트리의 각 리프 (Leaf) 노드는 메시지에서 사용되는 문자를 나타내며, 루트에서 해당 노드까지의 경로가 해당 문자의 부호가 된다.

허프만 부호화 과정 및 특징

- **허프만 부호화 과정:**

- 빈도 계산: 입력 데이터에서 각 문자의 빈도를 계산
- 트리 구성: 가장 빈도가 낮은 두 문자를 선택하여 이진 트리의 두 자식 노드로 만든다. 이 두 노드를 합쳐 하나의 부모 노드를 만들고, 그 빈도를 두 자식 노드의 빈도의 합으로 설정한다.
- 반복: 남은 모든 문자에 대해 같은 과정을 반복하여, 하나의 노드만 남을 때까지 트리를 구성한다.
- 부호 할당: 트리의 각 리프 노드에 도달하는 경로에 따라 각 문자에 이진 부호를 할당한다.

- **허프만 부호의 특징:**

- 무손실 압축: 허프만 부호화는 원본 데이터를 손실 없이 압축하고 복원할 수 있다.
- 최적 부호화: 주어진 빈도 분포에 대해 최적의 부호를 생성한다. 즉, 평균 부호 길이가 최소화됩니다.
- 적응형 압축: 데이터의 빈도 분포에 따라 부호화 방식이 달라진다.
- 허프만 부호화는 그 효율성 때문에 다양한 압축 알고리즘과 표준에서 사용된다. 예를 들어, JPEG 이미지 압축과 MP3 오디오 압축에서 이 방법이 활용된다.

허프만 부호화 예제

5가지의 심볼이 $\Pr(x_1)=\Pr(x_2)=\Pr(x_3)=0.25$, $\Pr(x_4)=\Pr(x_5)=0.125$ 의 확률 값으로 전송되는 경우, 이 심볼을 허프만 부호로 압축하여 전송하고자 한다.

① **빈도 정렬**: 각 상태 값을 확률에 따라 $x_5(0.125), x_4(0.125), x_3(0.25), x_2(0.25), x_1(0.25)$ 순으로 정렬한다.

② **트리 구성**: 가장 낮은 확률의 두 상태 값을 결합하여 트리의 노드를 만든다.

- 첫 번째 단계: $x_5(0.125)$ 와 $x_4(0.125)$ 를 결합하여 $x_5x_4(0.25)$ 노드 생성
- 남은 상태 값: $x_5x_4(0.25), x_3(0.25), x_2(0.25), x_1(0.25)$

③ **반복**: 위의 과정을 반복하여 트리를 완성


- 두 번째 단계: $x_5x_4(0.25), x_3(0.25)$ 를 결합하여 $x_5x_4x_3(0.5)$ 노드 생성
- 남은 상태 값: $x_2(0.25), x_1(0.25), x_5x_4x_3(0.5)$
- 세 번째 단계: $x_2(0.25), x_1(0.25)$ 를 결합하여 $x_2x_1(0.5)$ 노드 생성
- 남은 상태 값: $x_2x_1(0.5), x_5x_4x_3(0.5)$
- 마지막 단계: $x_2x_1(0.5), x_5x_4x_3(0.5)$ 를 결합하여 $x_2x_1x_5x_4x_3(1.0)$ 뿌리 노드 생성

④ **부호 할당**: 완성된 트리에서 각 리프 노드까지의 경로를 따라 부호를 할당

- x_1 : 01
- x_2 : 00
- x_3 : 11
- x_4 : 101
- x_5 : 100

허프만 부호: 1110000010011101100

해당 심볼: $x_3 x_5 x_2 x_1 x_2 x_3 x_4 x_5$



허프만 부호의 평균 부호 길이

5가지의 심볼의 발생 빈도 : $\Pr(x_1)=\Pr(x_2)=\Pr(x_3)=0.25$, $\Pr(x_4)=\Pr(x_5)=0.125$

- ✓ $H(x) = -\sum_{i=1}^5 \Pr(x_i) \log_2 \Pr(x_i) = 2.25$ bits
- ✓ 평균부호길이 = $\Pr(x_1) \times 2 + \Pr(x_2) \times 2 + \Pr(x_3) \times 2 + \Pr(x_4) \times 3 + \Pr(x_5) \times 3 = 2.25$ bits
- ✓ Entropy와 평균부호길이 동일
- ✓ 평균 부호 길이가 최소화되는 최적 부호화

